

Лекция 1. Кластеризация

Дополнительные главы машинного обучения

Автор занятия: Никитин Илья Сергеевич

Образовательная программа
«Машинное обучение в цифровом продукте»

Правила игры

Оценка за курс

$$O_{\text{накоп}} \cdot 0,6 + O_{\text{экзамен}} \cdot 0,4.$$

$O_{\text{накоп}}$ — накопленная оценка;

$O_{\text{экзамен}}$ — оценка за экзамен.

- **Экзамен устный.**
- За доклад на специальном семинаре с докладами — бонус **до 2 баллов** к итоговой оценке.
- Один вопрос на экзамене будет по докладам.



Чат курса

Оглавление

1) Задача кластеризации и K-means

2) Иерархическая кластеризация

3) DBSCAN

4) EM-алгоритм

5) Заключение

Задача кластеризации

Есть объекты $X = (x_1, \dots, x_n)^\top \in \mathbb{R}^{n \times d}$, но нет готовых меток. Например, хотим:

- разделить покупателей по частоте покупок и размеру корзины;
- собрать похожие жалобы клиентов: о доставке, оплате или качестве товара;
- сгруппировать фотографии с похожим содержанием.

Классы заданы заранее. Кластеры получаем из признаков и предположений метода.

Обсудим. Должны ли все изображения одной цифры образовать одну группу?

Задача кластеризации

Есть объекты $X = (x_1, \dots, x_n)^\top \in \mathbb{R}^{n \times d}$, но нет готовых меток. Например, хотим:

- разделить покупателей по частоте покупок и размеру корзины;
- собрать похожие жалобы клиентов: о доставке, оплате или качестве товара;
- сгруппировать фотографии с похожим содержанием.

Классы заданы заранее. Кластеры получаем из признаков и предположений метода.

Обсудим. Должны ли все изображения одной цифры образовать одну группу?


Ответ. Не обязательно: по пикселям почерк и толщина линии могут различаться сильнее, чем сами цифры. Результат зависит от представления изображений.

Что считается одной группой


Три возможных определения

- Близко к общему центру.
- Связано плотными окрестностями.
- Порождено одной компонентой.

Вокруг центра



Плотная область



Компонента распределения



Варианты ответа

- Жёстко: $z_i \in \{1, \dots, K\}$.
- Мягко: $r_{ik} \geq 0, \sum_k r_{ik} = 1$.
- С шумом: допускается метка -1 .

Расстояние задаёт геометрию

Евклидово расстояние: сравнивает величины координат.

$$d(x, y) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}.$$


Косинусное расстояние: сравнивает направления ненулевых векторов.

$$d_{\cos}(x, y) = 1 - \frac{x^{\top} y}{\|x\| \|y\|}.$$

Оно полезно, например, для текстовых векторов; в общем случае не удовлетворяет неравенству треугольника.

Единицы измерения, пропуски, выбросы и неинформативные признаки нужно обсудить *до* выбора алгоритма.

Масштаб меняет разбиение



$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

На рисунках одни координаты; обучающие данные различаются масштабом. Стандартизация выравнивает дисперсии, но не определяет содержательную важность признаков.

Высокая размерность и проекции

- Шумовые признаки могут заслонить различия между группами.
- PCA может убрать шум, но и направление малой дисперсии иногда разделяет нужные группы.
- t-SNE и UMAP помогают увидеть соседства, но меняют расстояния.

Оценивать разбиение следует в признаках и расстояниях, соответствующих задаче.

Обсудим. Почему два красивых облака на двумерной картинке ещё не достаточное доказательство?

Высокая размерность и проекции

- Шумовые признаки могут заслонить различия между группами.
- PCA может убрать шум, но и направление малой дисперсии иногда разделяет нужные группы.
- t-SNE и UMAP помогают увидеть соседства, но меняют расстояния.

Оценивать разбиение следует в признаках и расстояниях, соответствующих задаче.

Обсудим. Почему два красивых облака на двумерной картинке ещё не достаточное доказательство?

Ответ. Проекция может усилить разрывы между точками. Нужно проверить соседства и состав групп в исходных признаках, а также их устойчивость при изменении данных.

K-means: сумма квадратов до центров

$$J(z, \mu) = \sum_{i=1}^n \|x_i - \mu_{z_i}\|_2^2 \longrightarrow \min_{z, \mu}, \quad z_i \in \{1, \dots, K\}.$$

- $\mu_k \in \mathbb{R}^d$ — центр группы; он не обязан совпадать с объектом.
- K задаём заранее. Все объекты получают метки.
- Квадрат усиливает вклад далёких точек и делает оптимальным центром среднее.

Предположение: нужные группы достаточно компактны в выбранной евклидовой геометрии.

Алгоритм Ллойда

1. Назначение при фиксированных центрах


$$z_i \leftarrow \arg \min_{k=1,\dots,K} \|x_i - \mu_k\|^2.$$

2. Обновление при фиксированных назначениях

$$\mu_k \leftarrow \frac{1}{|C_k|} \sum_{i \in C_k} x_i, \quad C_k = \{i : z_i = k\}.$$

Повторяем до стабилизации центров или заданного предела итераций.


Центры уточняют описание покупателей



Сначала покупатели выбирают ближайший центр. Затем центры перемещаются к средним профилям. После этого часть назначений может измениться.

Обсудим. Почему для суммы квадратов берём среднее, а не медиану?

Центры уточняют описание покупателей



Сначала покупатели выбирают ближайший центр. Затем центры перемещаются к средним профилям. После этого часть назначений может измениться.

Обсудим. Почему для суммы квадратов берём среднее, а не медиану?

Ответ. Среднее минимизирует сумму квадратов расстояний. Медиана на прямой минимизирует другой критерий — сумму абсолютных отклонений.

Почему критерий не возрастает

При фиксированном C_k :

$$\frac{\partial}{\partial \mu_k} \sum_{i \in C_k} \|x_i - \mu_k\|^2 = 2|C_k|\mu_k - 2 \sum_{i \in C_k} x_i = 0.$$

- Назначение выбирает лучший центр для каждой точки.
- Обновление выбирает лучший центр для текущей группы.
- Значит, оба шага не увеличивают J .

Но совместная задача невыпукла: результат зависит от начальных центров.

Невозрастание критерия не означает глобальную оптимальность.

Инициализация и вычислительная стоимость


K-means++: первый центр случайный; следующие выбираются с вероятностью, пропорциональной квадрату расстояния до ближайшего уже выбранного центра.

- Несколько запусков: выбираем результат с наименьшим J .
- Одна итерация Ллойда: порядка $O(nKd)$, где n — число объектов, d — число признаков, K — число групп.
- MiniBatch K-means обновляет центры по небольшим порциям данных: быстрее, но с приближёнными обновлениями.

```
KMeans(n_clusters=3, n_init=20, random_state=42)
```

scikit-learn developers. KMeans. Справочник API.


Когда центры плохо описывают группы



K-means строит ячейки Вороного с линейными границами между парами центров. Полумесяц может быть связной группой, хотя его части далеко от среднего.

Выбросы, вытянутые формы и сильные различия в плотности тоже могут менять желаемое разбиение.

Выбор К: метод локтя



Больше центров дают больше возможностей уменьшить сумму квадратов расстояний J . **Локоть** — место, после которого новые центры дают уже небольшой выигрыш.

Выбираем разумный компромисс между точностью описания и числом групп. Отчётливый излом бывает не всегда.

Силуэт: компактность и отделённость

Для одной точки x_i сравним расстояния до своей и до других групп.

a_i : близость своей группы

Среднее расстояние от x_i до остальных точек её группы.

b_i : близость другой группы

Для каждой другой группы считаем среднее расстояние от x_i до её точек. Берём наименьшее из этих средних.



$$s_i = \frac{b_i - a_i}{\max(a_i, b_i)}, \quad -1 \leq s_i \leq 1.$$

- Близко к 1: своя группа заметно ближе других.
- Около 0: своя и ближайшая другая группа примерно одинаково близки.
- Меньше 0: в среднем точка ближе к другой группе.

Силуэт разбиения — среднее s_i по объектам; чем больше, тем лучше по этому критерию.

scikit-learn developers. Silhouette Coefficient. Руководство пользователя.

Метод локтя и силуэт



- **Локоть:** ищем, где замедляется улучшение суммы квадратов.
- **Силуэт:** ищем максимум среднего контраста между своей и другой группой.

Здесь оба подхода указывают на $K = 3$. Если рекомендации расходятся, сравниваем состав групп и соседние значения K .

Силуэт предпочитает компактные, отделённые группы и может плохо оценивать сложные формы.

Оглавление

1) Задача кластеризации и K-means

2) Иерархическая кластеризация

3) DBSCAN

4) EM-алгоритм

5) Заключение

Агломеративная иерархия

Начинаем с n отдельных точек; на каждом шаге объединяем две ближайшие группы.

Связь	Расстояние между A и B
Single	$\min_{x \in A, y \in B} d(x, y)$
Complete	$\max_{x \in A, y \in B} d(x, y)$
Average	$\frac{1}{ A B } \sum_{x \in A, y \in B} d(x, y)$

Число групп или высота среза определяют нужный уровень детализации.

Обсудим. Какой вариант легче объединит две группы через цепочку промежуточных точек?

Агломеративная иерархия

Начинаем с n отдельных точек; на каждом шаге объединяем две ближайшие группы.




Связь	Расстояние между A и B
Single	$\min_{x \in A, y \in B} d(x, y)$
Complete	$\max_{x \in A, y \in B} d(x, y)$
Average	$\frac{1}{ A B } \sum_{x \in A, y \in B} d(x, y)$

Число групп или высота среза определяют нужный уровень детализации.

Обсудим. Какой вариант легче объединит две группы через цепочку промежуточных точек?

Ответ. Single linkage: для слияния достаточно одной близкой пары. Цепочка таких пар может соединить два далёких облака.

Как читать дендрограмму



- Высота — значение критерия слияния.
- Горизонтальный срез пересекает ветви получившихся групп.
- Порядок листьев не задаёт расстояния между объектами.

Метод Ward: сохраняем компактность групп

Объединяем группы, для которых переход к общему центру меньше всего увеличит сумму квадратов расстояний:

$$\Delta(A, B) = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|^2.$$

μ_A, μ_B — средние профили групп; $|A|, |B|$ — их размеры.

- Квадраты расстояний считаем между числовыми профилями объектов, как в K-means. Поэтому важен сопоставимый масштаб признаков.
- Выбираем лучшее слияние на текущем шаге. Позже алгоритм уже не разделит объединённую группу обратно.
- Хранение расстояний между парами объектов требует много памяти: в стандартной реализации — порядка n^2 чисел.

SciPy developers. `scipy.cluster.hierarchy.linkage`. Справочник API.

Дивизивная кластеризация: от общего к частному

Агломеративный подход объединяет группы. **Дивизивный** действует в противоположном направлении — последовательно делит их.

Все объекты вместе $\longrightarrow$ Две группы $\longrightarrow$ Более мелкие группы.

1. Начинаем с одной группы, содержащей всю выборку.
2. Выбираем группу для деления, например с большим разбросом.
3. Разбиваем её на части; простой вариант — K-means с $K = 2$.
4. Повторяем до нужного числа групп или другого условия остановки.

Получается иерархия разделений. Она не обязана совпадать с результатом агломеративного алгоритма.

scikit-learn developers. BisectingKMeans. Справочник API.

Оглавление

1) Задача кластеризации и K-means

2) Иерархическая кластеризация

3) DBSCAN

4) EM-алгоритм

5) Заключение

DBSCAN: ядро, граница и шум

$$N_\varepsilon(x) = \{x_j : d(x, x_j) \leq \varepsilon\}.$$

- **Ядро:** $|N_\varepsilon(x)| \geq m$, где $m = \text{min_samples}$.
- **Граница:** не ядро, но находится в окрестности ядра.
- **Шум:** не принадлежит ни одному из найденных кластеров.

В scikit-learn точка входит в собственную окрестность.

Расширяем группу через ядра. Граничные точки добавляем, но через них расширение не продолжаем.

Ester, Kriegel, Sander, Xu (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. KDD.

DBSCAN: расширение плотной группы

1. Начинаем группу с ещё не обработанного ядра.
2. Добавляем его соседей в радиусе ε .
3. Через новые ядра продолжаем расширение, пока группа растёт.
4. Повторяем для оставшихся ядер. Не присоединённые точки — шум.

Граничная точка может соседствовать с разными группами. Её метка иногда зависит от порядка обработки; разбиение ядер определено однозначно.

Обсудим. Может ли цепочка только из граничных точек соединить две группы?

DBSCAN: расширение плотной группы

1. Начинаем группу с ещё не обработанного ядра.
2. Добавляем его соседей в радиусе ε .
3. Через новые ядра продолжаем расширение, пока группа растёт.
4. Повторяем для оставшихся ядер. Не присоединённые точки — шум.

Граничная точка может соседствовать с разными группами. Её метка иногда зависит от порядка обработки; разбиение ядер определено однозначно.

Обсудим. Может ли цепочка только из граничных точек соединить две группы?

Ответ. Нет: граничную точку можно добавить, но через неё расширение не продолжается. Соединить группы может только цепочка ядер.

Как выбирать плотностной масштаб



- Малый eps: много шума и фрагментов.
- Большой eps: слияние областей.
- График расстояний до m -го соседа даёт диапазон для проверки.

Оцениваем число групп, покрытие и чувствительность к параметрам.

Общий eps трудно подобрать, если нужные группы имеют разные плотности.

HDBSCAN: учитываем окружение точек

Тесное облако сохраняется при малом радиусе. Для широкого облака нужен больший радиус, но он может слить соседние группы.

Пусть $c_m(x)$ — минимальный радиус, содержащий хотя бы m объектов вокруг x , включая саму точку. Используем расстояние

$$d_{\text{mr}}(x, y) = \max\{c_m(x), c_m(y), d(x, y)\}.$$

Пара считается близкой при пороге ε , только если:


- расстояние между точками не больше ε ;
- у каждой точки достаточно соседей в этом радиусе.

Если вокруг близкой пары не хватает соседей, условие плотности не выполнится.

Campello, Moulavi, Sander (2013). Density-Based Clustering Based on Hierarchical Density Estimates. PAKDD.

HDBSCAN: меняем радиус соседства

Уменьшаем радиус ϵ : теперь нужное число соседей должно находиться всё ближе к каждой точке.



- Большой радиус соединяет оба облака; средний разделяет их.
- При малом радиусе остаётся тесное облако. Разреженное становится шумом — серые точки справа.
- HDBSCAN учитывает всю последовательность и в этом примере сохраняет обе группы. Один общий радиус выбирать не нужно.

Оглавление

- 1) Задача кластеризации и K-means
- 2) Иерархическая кластеризация
- 3) DBSCAN
- 4) EM-алгоритм**
- 5) Заключение


Две группы покупателей

В одной группе обычно собирают небольшую корзину, в другой — большую. Но корзины перекрываются: покупка среднего размера допускает оба объяснения.

- Если бы знали группы, оценили бы средние, разбросы и доли.
- Если бы знали распределения, оценили бы принадлежность покупателей.


Идея ЕМ: начать с приблизительных распределений и уточнять эти две части по очереди. Готовые метки не нужны даже для первого шага.

Начальное предположение



Колокол описывает типичный размер корзины и разброс вокруг него. Покупатель Б находится в области перекрытия: сразу выбирать одну группу было бы преждевременно.

Е-шаг: сохраняем несколько объяснений



Для каждого покупателя сравниваем плотности и доли групп, затем нормируем веса. Высота столбца — все вероятности вместе; части — возможные объяснения.

Покупатель между группами влияет на обе компоненты: неопределённость сохраняется в весах r_{ik} .

Формула Е-шага

$$r_{ik} = P(z_i = k \mid x_i, \theta) = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \sigma_k^2)}{\sum_{\ell} \pi_{\ell} \mathcal{N}(x_i \mid \mu_{\ell}, \sigma_{\ell}^2)}.$$

- Плотность: насколько наблюдение типично для группы.
- Доля π_k : насколько группа распространена.
- Нормировка: все объяснения одного покупателя в сумме дают единицу.

Е — expectation: вместо неизвестных индикаторов принадлежности используем их условные ожидания.

Dempster, Laird, Rubin (1977). Maximum Likelihood from Incomplete Data via the EM Algorithm. JRSS B.

М-шаг: сильнее учитывать тех, кто больше похож

Покупатель с большим весом сильнее влияет на параметры группы. Пограничный покупатель влияет сразу на несколько групп.


$$N_k = \sum_i r_{ik}, \quad \mu_k^{\text{new}} = \frac{\sum_i r_{ik} x_i}{N_k}, \quad \pi_k^{\text{new}} = \frac{N_k}{n}.$$

Разброс тоже становится взвешенным и считается относительно нового среднего:

$$\sigma_k^{2\text{new}} = \frac{\sum_i r_{ik} (x_i - \mu_k^{\text{new}})^2}{N_k}.$$

М — maximization: параметры лучше согласуются с текущими мягкими назначениями.

Новые параметры — новые вероятности



После движения и изменения ширины колоколов старые веса устаревают. Снова вычисляем принадлежность, затем пересчитываем параметры. Чёрная линия — суммарная плотность.

Что улучшается на итерациях EM

$$\ell(\theta) = \sum_i \log \left[\sum_k \pi_k \mathcal{N}(x_i \mid \mu_k, \sigma_k^2) \right].$$

Большая плотность в наблюдаемых значениях даёт большее правдоподобие.
Точный EM не уменьшает его, но может прийти к разным локальным решениям.
Поэтому сравниваем несколько запусков с разными начальными параметрами.

Обсудим. Почему два одинаковых колокола не разойдутся после E- и M-шагов?

Что улучшается на итерациях EM

$$\ell(\theta) = \sum_i \log \left[\sum_k \pi_k \mathcal{N}(x_i \mid \mu_k, \sigma_k^2) \right].$$

Большая плотность в наблюдаемых значениях даёт большее правдоподобие. Точный EM не уменьшает его, но может прийти к разным локальным решениям. Поэтому сравниваем несколько запусков с разными начальными параметрами.

Обсудим. Почему два одинаковых колокола не разойдутся после E- и M-шагов?

Ответ. Одинаковые параметры и доли дают одинаковые веса на E-шаге. M-шаг снова получает одинаковые параметры — симметрия сохраняется.

Несколько признаков: смесь Гаусса

Вектор x_i может включать средний чек и частоту покупок. Среднее μ_k становится вектором, а разброс описывается матрицей Σ_k :

$$p(x) = \sum_k \pi_k \mathcal{N}(x \mid \mu_k, \Sigma_k).$$


Е-шаг по-прежнему вычисляет вероятности групп. На М-шаге:

$$\mu_k^{\text{new}} = \frac{\sum_i r_{ik} x_i}{N_k}, \quad \Sigma_k^{\text{new}} = \frac{\sum_i r_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^{\top}}{N_k}.$$

Внедиагональные ковариации позволяют описать повёрнутое вытянутое облако.

scikit-learn developers. Gaussian mixture models. Руководство пользователя.

Мягкая принадлежность и форма компоненты



Цвет справа показывает наибольшую из вероятностей r_{ik} . Где она меньше, несколько компонент объясняют точку сопоставимо хорошо.

Чтобы получить одну метку, выбираем компоненту с наибольшей вероятностью:

$$z_i = \arg \max_k r_{ik}.$$

Связь EM с K-means

Пусть у компонент одинаковые доли $\pi_k = 1/K$ и одинаковая фиксированная сферическая ковариация $\Sigma_k = \sigma^2 I$. Тогда

$$r_{ik} \propto \exp \left(-\frac{\|x_i - \mu_k\|^2}{2\sigma^2} \right).$$

При уменьшении σ^2 всё больший вес получает ближайший центр.

Если ближайший центр единственный, при $\sigma^2 \rightarrow 0$ назначения становятся жёсткими, а взвешенные средние превращаются в обычные средние групп. Получаем шаги Ллойда.

При разных ковариациях или конечном разбросе GMM и K-means решают разные задачи.

Выбор числа компонент: BIC

Дополнительные компоненты позволяют лучше подогнать смесь к выборке. Чтобы не усложнять модель без достаточного выигрыша, учитываем и качество описания, и число параметров.

$$\text{BIC} = -2\ell(\hat{\theta}) + \nu \log n.$$

- $\ell(\hat{\theta})$ — логарифм правдоподобия обученной смеси.
- ν — число свободных параметров; n — число объектов.
- Первое слагаемое поощряет соответствие данным, второе штрафует за сложность. **Меньший BIC предпочтительнее.**

Сравниваем смеси на одних объектах и признаках, используя несколько инициализаций. Число компонент не обязано совпадать с числом содержательных групп.

Оглавление

- 1) Задача кластеризации и K-means
- 2) Иерархическая кластеризация
- 3) DBSCAN
- 4) EM-алгоритм
- 5) Заключение**

Выбор метода по задаче

Что нужно	Начальный кандидат	Что проверить
Компактные группы, много объектов	K-means / MiniBatch	Масштаб, K , выбросы
Несколько уровней детализации	Иерархия	Связь, высота среза, память
Протяжённые области и шум	DBSCAN / HDBSCAN	Плотность, шум, параметры
Эллипсоиды и мягкие значения	GMM	Ковариации, BIC, сходимость

Каждый кандидат нужно проверить на цели анализа и изменениях данных.

Нейросетевые представления и классический алгоритм

текст / изображение $\xrightarrow{f_\theta}$ вектор h_i $\xrightarrow{\text{K-means / HDBSCAN}}$ группа.

- Представление может учитывать смысл, который плохо выражен исходными координатами.
- Модель признаков и критерий кластеризации решают разные задачи.
- Проверяем нормировку, расстояния, смещение данных и содержательность групп.

Базовая модель для сравнения: TF-IDF + K-means для текстов.

Спасибо за внимание!