

Лекция 1. Кластеризация

Конспект лекции

Автор занятия: Никитин Илья Сергеевич

Дополнительные главы машинного обучения
МОЦП

1 Что мы называем кластером

У магазина есть история покупок, но нет готового списка покупательских групп. Для каждого человека можно посчитать средний чек, число покупок, долю заказов со скидкой и другие показатели. Хотелось бы понять, встречаются ли среди покупателей похожие типы поведения. Например, одни приходят часто и покупают понемногу, другие делают редкие крупные заказы. Для поиска таких групп применяют кластеризацию.

В задаче классификации мы заранее знаем, какие категории хотим различать, и обучаемся на примерах с метками. Здесь меток нет. Более того, сами категории ещё предстоит предложить. Алгоритм получает признаки и правило, по которому объекты следует считать близкими. Найденные группы называются *кластерами*.

Одни и те же данные допускают разные разумные разбиения. Если учитывать только средний чек, будут выделяться группы по уровню расходов. Если добавить состав покупок, могут появиться группы по интересам. Поэтому прежде всего нужно понять, для чего будут использованы кластеры. Сегменты для выбора ассортимента и сегменты для планирования доставки могут различаться.

1.1 Обозначения

Пусть есть n объектов, каждый описан d признаками. Вектор $x_i \in \mathbb{R}^d$ содержит признаки объекта i , а матрица $X \in \mathbb{R}^{n \times d}$ — всю выборку. Номер группы обозначим z_i , число групп — K :

$$z_i \in \{1, \dots, K\}, \quad C_k = \{i : z_i = k\}.$$

Множество C_k содержит индексы объектов группы k . Номер — всего лишь имя: если переименовать синюю группу в зелёную, состав группы от этого не изменится.

Некоторые методы обязательно распределяют все объекты. Другие разрешают оставить часть наблюдений вне кластеров, например если около них слишком мало соседей. Есть и методы, которые вместо одного номера возвращают вероятности принадлежности разным группам. Такая неопределённость полезна, когда группы перекрываются.

Кластер не обязан совпадать с известным классом. В изображениях одной цифры могут выделиться разные почерки, а в одном покупательском сегменте могут оказаться люди с разными профессиями. Смысл найденных групп проверяют после обучения: смотрят на характерные объекты, сравнивают признаки и обсуждают, помогает ли разбиение решать исходную задачу.

2 Как признаки превращаются в расстояния

Большинство методов кластеризации прямо или косвенно используют расстояния. Для числовых векторов привычный выбор — евклидово расстояние:

$$d(x, y) = \sqrt{\sum_{j=1}^d (x_j - y_j)^2}.$$


В каждой координате берётся разность, её квадрат добавляется к общей сумме. Поэтому единицы измерения существенно влияют на результат. Расходы, записанные в рублях, обычно имеют больший численный масштаб, чем число визитов. Поэтому они могут почти целиком определять расстояние, даже если возвращаемость покупателей для нас не менее важна.

2.1 Масштабирование

Обычная стандартизация вычитает среднее столбца и делит на его стандартное отклонение:

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}.$$

Разность в одну единицу теперь означает одно стандартное отклонение. Так признаки получают сопоставимый масштаб.



Во втором опыте изменены единицы измерения второго признака перед обучением. Все результаты показаны в исходных координатах: точки на рисунках остались на месте, но их группировка изменилась. После стандартизации снова выделяются два облака, разнесённых по первому признаку.

Стандартизация сама по себе не устанавливает правильные веса признаков. Если столбец содержит только шум, увеличение его относительного вклада может помешать. Если расходы имеют длинный правый хвост, сначала бывает полезен логарифм: увеличение небольшой корзины вдвое становится сопоставимым с таким же относительным увеличением большой корзины. Такое преобразование соответствует сравнению относительных, а не абсолютных различий.

Преобразования следует выбирать вместе с постановкой задачи. Для покупателей с одинаковым составом корзины, но разным общим бюджетом может быть важнее соотношение категорий, чем суммарная стоимость.

3 Другие расстояния и высокая размерность

Для ненулевых векторов косинусное расстояние определяется формулой

$$d_{\cos}(x, y) = 1 - \frac{x^{\top} y}{\|x\| \|y\|}.$$

Оно сравнивает направления. Если два покупателя распределяют расходы между категориями в одинаковых пропорциях, их векторы направлены одинаково, хотя общий бюджет может различаться. Для текстов это позволяет сопоставлять относительный состав слов, не придавая решающего значения длине документа. Косинусное расстояние в общем случае не удовлетворяет неравенству треугольника, поэтому не всякий алгоритм, рассчитанный на строгую метрику, можно применять без проверки.

Для единичных векторов справедливо $\|x - y\|^2 = 2(1 - x^{\top} y)$. Это связывает косинусное сходство с евклидовым расстоянием после нормировки. Но из равенства не следует, что обычный K-means автоматически становится сферическим: среднее нескольких единичных векторов обычно уже не имеет единичной длины.

3.1 Почему лишние признаки могут мешать

Предположим, что два полезных признака хорошо разделяют группы, а остальные, гораздо более многочисленные, — случайные измерения. Расстояние складывается по всем координатам. Суммарный вклад шума может заслонить различие в двух полезных признаках. В некоторых высокоразмерных распределениях расстояния до разных точек становятся близкими друг к другу относительно их величины, и понятие «ближайший сосед» теряет контраст.

Поэтому перед кластеризацией полезно проверить происхождение столбцов, убрать дубликаты и заведомо неинформативные измерения. PCA иногда помогает сократить размерность и шум. Однако PCA сохраняет направления большой дисперсии, а они не обязательно лучше всего отделяют нужные группы. Небольшое, но устойчивое различие может находиться в направлении с малой дисперсией.

3.2 Что можно узнать из двумерной картинки

PCA, t-SNE и UMAP позволяют изображать многомерные объекты на плоскости. Картинка помогает находить необычные точки и формулировать гипотезы. Но проекция меняет расстояния; заметные «острова» могут зависеть от параметров отображения. Проверять кластеры нужно в том пространстве, в котором определена задача.

Если кластеризация выполняется на уменьшенном представлении, само преобразование становится частью модели. Тогда стоит сравнить несколько размерностей и проверить, сохраняются ли группы. Хорошая визуализация объясняет результат, но не заменяет его оценку.

4 K-means: группа вокруг среднего

Начнём с предположения, что каждую группу удобно описать одним центром. Точки одной группы должны располагаться достаточно близко к нему. Обозначим центр группы k через $\mu_k \in \mathbb{R}^d$. K-means подбирает центры и назначения так, чтобы уменьшить сумму квадратов расстояний:

$$J(z, \mu) = \sum_{i=1}^n \|x_i - \mu_{z_i}\|^2 = \sum_{k=1}^K \sum_{i \in C_k} \|x_i - \mu_k\|^2.$$

Число K задаётся заранее. Все объекты получают номера групп. Центр — средний вектор признаков; ему не обязательно соответствует реальный объект. Например, средняя частота покупок может оказаться дробной.

4.1 Алгоритм Ллойда

Одновременно выбрать все назначения и все центры трудно. Если одну часть решения зафиксировать, другая находится просто.

При известных центрах каждый объект отправляется к ближайшему:

$$z_i \leftarrow \arg \min_k \|x_i - \mu_k\|^2.$$


При известных назначениях каждый центр заменяется средним своей группы:

$$\mu_k \leftarrow \frac{1}{|C_k|} \sum_{i \in C_k} x_i.$$

После пересчёта центров ближайшая группа для некоторых точек может измениться. Поэтому снова выполняется назначение, затем снова пересчитываются средние. Алгоритм останавливают, когда центры почти перестали двигаться или достигнут заданный предел итераций.

4.2 Как выглядит движение центров

Представим покупателей на плоскости «число заказов — размер корзины». Поставим приблизительные центры в разных частях облака. Сначала каждый покупатель выбирает ближайший центр. Затем центры перемещаются к средним профилям тех, кто к ним попал.



Кресты обозначают центры, стрелки — их движение. Облако покупателей остаётся тем же: меняется описание облака. После движения центров граница между группами может сдвинуться, и часть покупателей сменит группу. Это и объясняет, зачем повторять назначения.

5 Почему в K-means появляется среднее

Для фиксированной непустой группы рассмотрим функцию от её центра:

$$F(\mu) = \sum_{i \in C} \|x_i - \mu\|^2.$$

Её градиент равен

$$\nabla F(\mu) = 2|C|\mu - 2 \sum_{i \in C} x_i.$$

Приравнивая его нулю, получаем среднее. Матрица вторых производных равна $2|C|I$ и положительно определена, поэтому это единственный минимум по центру.

Есть и геометрическое объяснение. Если $\bar{x}$ — среднее группы, то

$$\sum_{i \in C} \|x_i - \mu\|^2 = \sum_{i \in C} \|x_i - \bar{x}\|^2 + |C| \|\mu - \bar{x}\|^2.$$

Первое слагаемое от μ не зависит, а второе минимально при $\mu = \bar{x}$. Равенство следует из раскрытия скобок и того, что сумма отклонений от среднего равна нулю.

5.1 Что гарантирует чередование шагов

На шаге назначения каждая точка выбирает наилучший из текущих центров. На шаге обновления каждая группа получает наилучший центр для текущего состава. Значит,

$$J(z^{(t+1)}, \mu^{(t+1)}) \leq J(z^{(t+1)}, \mu^{(t)}) \leq J(z^{(t)}, \mu^{(t)}).$$

Критерий не возрастает и ограничен снизу нулём. Однако из этого не следует, что найден глобальный минимум. Алгоритм улучшает две части решения по очереди и может остановиться на неудачном их сочетании.

Если к центру не назначилась ни одна точка, среднее не определено. Реализация должна предусмотреть этот случай: например, перенести пустой центр в область, которую пока плохо описывают другие центры.

5.2 Начальные центры

Случайная инициализация иногда помещает несколько центров в одно облако. K-means++ пытается избежать этого: первый центр выбирается случайно, а вероятность выбора следующей точки пропорциональна квадрату расстояния до ближайшего уже выбранного центра. Поэтому плохо покрытые области имеют больше шансов получить собственный центр.


Обычно выполняют несколько запусков и выбирают наименьшее значение J . Один обычный шаг назначения требует порядка $O(nKd)$ операций. Для больших выборок используют MiniBatch K-means: параметры обновляются по небольшим порциям объектов.

6 Когда одного центра недостаточно

Граница между двумя группами K-means задаётся равенством

$$\|x - \mu_a\|^2 = \|x - \mu_b\|^2.$$

После раскрытия скобок квадраты координат x сокращаются, и остаётся линейное уравнение. При фиксированных центрах получаются ячейки Вороного: каждая состоит из точек, ближайших к своему центру. Такая геометрия подходит компактным облакам, но не любой связной области.



У полумесяца есть две далёкие части, соединённые непрерывной полосой точек. Среднее не описывает его форму. Поэтому K-means разрезает полумесяцы, хотя по связности естественно видеть две другие группы. Позже рассмотрим плотностные методы, результаты которых также показаны на рисунке.

Квадрат расстояния делает K-means чувствительным к выбросам. Один оптовый покупатель с очень большой корзиной способен заметно сдвинуть средний профиль всей группы. В результате центр станет хуже описывать большинство обычных покупателей. Если такой объект не должен влиять на основную группу, нужно изменить постановку или обработку данных.

6.1 Как выбирать число групп

Оптимальная сумма квадратов не увеличивается при добавлении центра: $J_{K+1}^* \leq J_K^*$. При $K = n$ можно поставить центр в каждую точку и получить нуль. Поэтому выбирать K простым минимумом суммы квадратов нельзя.

Метод локтя ищет место, после которого добавление центров даёт сравнительно небольшое улучшение. Иногда излом хорошо заметен, иногда кривая плавная. Кроме того, конкретные запуски находят локальные решения, и вычисленные значения могут слегка нарушать теоретическую монотонность. Локоть полезно рассматривать вместе с геометрией групп, их размерами и устойчивостью.

7 Оценка без эталонных меток

В классификации можно сравнить предсказания с ответами. В кластеризации ответов часто нет, поэтому приходится уточнять, какое свойство разбиения нас устраивает. Например, внутренние метрики оценивают компактность групп и расстояния между ними.

7.1 Силуэт

Для точки x_i вычислим среднее расстояние до остальных точек её группы:


$$a_i = \frac{1}{|C_{z_i}| - 1} \sum_{j \in C_{z_i}, j \neq i} d(x_i, x_j).$$

Затем для каждой другой группы посчитаем среднее расстояние до её точек и выберем минимальное:

$$b_i = \min_{k \neq z_i} \frac{1}{|C_k|} \sum_{j \in C_k} d(x_i, x_j).$$

Силуэт точки равен $s_i = (b_i - a_i) / \max(a_i, b_i)$. Если свои соседи в среднем заметно ближе чужих, силуэт положителен и велик. Если ближайшая чужая группа в среднем ближе собственной, силуэт отрицателен. Точка на границе похожих групп получает значение около нуля.

Силуэт разбиения — среднее по объектам. Для одиночной точки его принято считать равным нулю. Если есть только одна группа, величина b_i не определена; общая оценка применяется при числе непустых групп от 2 до $n - 1$. В случае $a_i = b_i = 0$ также используется нуль.



Для разделённых облаков локоть и силуэт указывают на три группы. Но на полумесяцах силуэт может предпочесть разбиение K-means: компактные фрагменты лучше соответствуют его определению, чем длинные связные полосы. Метрика оценивает выбранное свойство, а не общий смысл групп.

Если алгоритм оставляет шум, правила расчёта нужно указать отдельно. Силуэт без шума характеризует только оставшиеся точки. Оценку на небольшом остатке выборки нельзя напрямую сопоставлять с оценкой почти на всех покупателях, забыв о покрытии и составе исключённых наблюдений.

8 Сравнение разбиений и устойчивость

Предположим, что у нас есть два разбиения одних объектов. Номера групп могут различаться, поэтому доля совпавших номеров не подходит. Вместо этого можно рассматривать пары: оказались ли два объекта вместе в обоих разбиениях или отдельно в обоих.

ARI, скорректированный индекс Рэнда, оценивает согласие таких пар с поправкой на случайные совпадения. Значение 1 соответствует одинаковым группам с точностью до переименования. Значение около 0 — случайному уровню в используемой модели случайных разбиений; возможны отрицательные значения.

8.1 Как получается поправка

Пусть n_{ab} — число объектов в пересечении группы a первого разбиения и группы b второго. Обозначим размеры групп $u_a = \sum_b n_{ab}$ и $v_b = \sum_a n_{ab}$. Число пар, объединённых обоими разбиениями, равно $T = \sum_{ab} \binom{n_{ab}}{2}$. Положим

$$A = \sum_a \binom{u_a}{2}, \quad B = \sum_b \binom{v_b}{2}, \quad M = \binom{n}{2}.$$

При случайном сочетании разбиений с фиксированными размерами групп ожидается AB/M совместно объединённых пар. Отсюда

$$\text{ARI} = \frac{T - AB/M}{(A + B)/2 - AB/M}.$$

Формула записана для невырожденного случая. В предельных случаях библиотека использует отдельные соглашения. Поправка на случайность не устраняет полностью влияние дисбаланса и структуры групп.

8.2 Как использовать ARI без разметки

Можно повторить обучение с другими начальными параметрами и сравнить результаты. Это проверяет, насколько устойчиво работает оптимизация. Можно менять подвыборки и сравнивать назначения только общих объектов. Такая проверка уже показывает чувствительность к составу данных.

Если масштабирование обучается по выборке, его тоже нужно заново оценивать внутри каждого повторения. Иначе часть конвейера останется зафиксированной по полным данным. Для методов с шумом полезно отдельно считать, как часто объекты переходят из кластеров в шум и обратно.

Устойчивое разбиение ещё нужно интерпретировать. Например, оно может очень стабильно разделять пользователей по способу заполнения анкеты, хотя нас интересует покупательское поведение. Полезно посмотреть на несколько типичных и пограничных объектов каждой группы и объяснить, какие признаки определили их соседство.

9 Иерархическая кластеризация


Иногда одного уровня группировки недостаточно. Покупателей можно сначала разделить на крупные сегменты, затем выделить внутри них более узкие группы. Иерархическая кластеризация описывает такие вложенные группы. Построить их можно в двух направлениях: объединять небольшие группы в более крупные или последовательно делить исходную выборку.

Агломеративный алгоритм начинается с n отдельных точек. На каждом шаге он объединяет две ближайшие группы. Чтобы продолжить, нужно определить расстояние между множествами, а не только между отдельными объектами:

$$d_{\text{single}}(A, B) = \min_{x \in A, y \in B} d(x, y), \quad d_{\text{complete}}(A, B) = \max_{x \in A, y \in B} d(x, y),$$

$$d_{\text{average}}(A, B) = \frac{1}{|A||B|} \sum_{x \in A, y \in B} d(x, y).$$

Для single linkage достаточно одной близкой пары. Поэтому промежуточные точки могут связать далёкие концы в длинную цепочку. Complete linkage смотрит на самую далёкую пару и требует большей компактности. Average linkage усредняет все межгрупповые расстояния.



На дендрограмме высота слияния соответствует значению выбранного критерия. Горизонтальный срез задаёт разбиение: группы образуются из ветвей, соединённых ниже среза. На высоте 1.1 single linkage объединяет все восемь точек, а complete linkage даёт группы (0, 1, 2), (3, 4) и (5, 6, 7). Порядок листьев по горизонтали не является шкалой расстояний.

9.1 Критерий Ward

Ward выбирает слияние с минимальным увеличением суммы квадратов внутри групп:

$$\Delta(A, B) = \frac{|A||B|}{|A| + |B|} \|\mu_A - \mu_B\|^2.$$

Он связан с критерием K-means и требует евклидовой геометрии. В SciPy высота Ward равна $\sqrt{2\Delta}$. Решения об объединении жадные: ошибочное слияние позже не отменяется. Стандартные плотные реализации также требуют порядка n^2 памяти, что ограничивает размер выборки.

9.2 Дивизивная кластеризация

Дивизивный алгоритм движется от общего к частному. Вначале все объекты входят в одну группу. Затем алгоритм выбирает одну из текущих групп, делит её на части и повторяет этот шаг. Например, среди покупателей сначала могут отделиться частые посетители от тех, кто покупает редко. На следующем уровне группа частых посетителей может разделиться на покупателей с небольшими и крупными корзинами. Такие названия мы даём после анализа признаков получившихся групп; заранее алгоритму они неизвестны.

Простой способ построить такую иерархию — *bisecting K-means*, то есть последовательное деление с помощью K-means. Внутри выбранной группы запускают K-means с двумя центрами. Её объекты распределяются между двумя новыми группами, а остальные группы остаются без изменений. Повторное деление уточняет уже найденную структуру, сохраняя принадлежность каждой новой группы к её исходной группе.

Нужно отдельно задать, какую группу делить следующей. Один вариант — выбирать группу с наибольшей суммой квадратов расстояний до её центра: она вносит наибольший вклад в общий критерий K-means. Другой вариант — делить самую многочисленную группу. Оба правила доступны в `BisectingKMeans` в `scikit-learn`. Остановиться можно при достижении заданного числа групп K : начиная с одной группы, для этого потребуется $K - 1$ делений.

Направление здесь противоположно агломеративному, но дивизивный алгоритм не воспроизводит слияния в обратном порядке. На каждом шаге он решает новую задачу разбиения. Поэтому два подхода на одних данных могут дать разные иерархии. Раннее неудачное разделение также ограничивает последующие решения: объекты из разных его частей уже не окажутся вместе при дальнейших делениях.

10 DBSCAN: группа как плотная связная область

Для полумесяца расстояние до центра неудобно, но соседние точки вдоль полосы близки. Возникает другая идея: объединять области, внутри которых можно переходить от точки к точке через достаточно плотные окрестности.

Пусть ε — радиус соседства:

$$N_\varepsilon(x) = \{x_j : d(x, x_j) \leq \varepsilon\}.$$

Точка называется *ядром*, если в её окрестности не меньше m объектов. В scikit-learn сама точка тоже учитывается. Поэтому при переносе параметров из другой реализации нужно проверить, включается ли центр окрестности в число соседей.

Неядерная точка рядом с ядром называется *граничной*. Она может принадлежать группе, хотя сама не находится в достаточно плотном месте. Точки, не присоединённые ни к одной группе, получают метку шума -1 .

10.1 Как происходит объединение

Начнём с одного ядра и добавим в его группу всех соседей в радиусе ε . Если среди добавленных точек тоже есть ядра, рассмотрим и их окрестности. Будем повторять расширение, пока не останется новых соседей. Затем найдём ещё не обработанное ядро и начнём следующую группу.

Продолжать расширение можно через ядра, но не через граничные точки. Иначе тонкая цепочка случайных наблюдений могла бы соединить две плотные группы. Если граничная точка соседствует с ядрами разных групп, её метка может зависеть от порядка обработки. Разбиение самих ядер при фиксированных параметрах определено однозначно.

10.2 Выбор параметров

При маленьком ε даже одна полоса распадается на фрагменты, а многие точки становятся шумом. При большом радиусе соседними оказываются разные полосы и сливаются. Порог m определяет, какую локальную концентрацию точек считать достаточной.

Для фиксированного m полезно построить отсортированные расстояния до m -го соседа. Изменение наклона может подсказать диапазон радиусов. Однако результат зависит от плотности данных, и единственного правильного излома может не быть.

Шумовая метка означает только несоответствие выбранному плотностному критерию. Редкая, но содержательно важная группа тоже может оказаться шумом. Поэтому вместе с разбиением рассматривают долю исключённых объектов, размеры кластеров и чувствительность к параметрам.

11 HDBSCAN и неодинаковая плотность

Представим покупателей на плоскости «частота покупок — средний чек». Одни образуют тесное облако, другие — более широкое. Для DBSCAN трудно подобрать общий радиус: при малом широкое облако распадается, а при большом соседние группы могут слиться.

HDBSCAN рассматривает последовательность уровней плотности. Если постепенно уменьшать допустимое расстояние, облака отделяются друг от друга, теряют редкие точки на окраинах и затем распадаются. Алгоритм отслеживает, какие группы сохраняются на разных уровнях.

11.1 Близость с учётом окружения


Одной близости двух точек недостаточно: нужно учитывать, сколько рядом других наблюдений. Обозначим через $c_m(x)$ наименьший радиус, содержащий хотя бы m объектов, включая саму точку. В плотном облаке он мал, в разреженном — велик. Определим *расстояние взаимной достижимости*:

$$d_{\text{mg}}(x, y) = \max\{c_m(x), c_m(y), d(x, y)\}.$$

Условие $d_{\text{mg}}(x, y) \leq \varepsilon$ требует и близости точек, и достаточного числа соседей вокруг каждой. Поэтому случайная близкая пара не соединит группы, если её окружение слишком разрежено.

При фиксированном пороге объединяем точки, между которыми можно пройти последовательностью таких пар. Уменьшение порога разделяет группы и создаёт иерархию. Граничные точки, как в обычном DBSCAN, к этим группам отдельно не присоединяются.

11.2 Выбор групп из иерархии



На первых трёх рисунках требование к плотности ужесточается. Серым показаны точки вне достаточно крупных групп. Широкое облако справа исчезает раньше тесного слева. HDBSCAN сохраняет обе группы, учитывая их существование в иерархии, а не выбирая один общий срез.

Иерархию сначала упрощают: отделение части меньше `min_cluster_size` считается потерей точек. Разделение на две самостоятельные группы сохраняется, только если обе достаточно крупные.

Затем оценивают *устойчивость* групп по шкале $\lambda = 1/\epsilon$: чем больше λ , тем строже требование к плотности. Для каждого объекта находят разность между уровнем его выхода из группы и уровнем появления группы; эти разности суммируют. Так учитываются и размер группы, и диапазон уровней, на котором её точки остаются вместе.

Стандартный способ выбора сравнивает устойчивость группы с суммарной устойчивостью выбранных внутри неё подгрупп. Группу и её вложенную часть одновременно не выбирают. Это позволяет сохранить тесное и широкое облака из разных частей иерархии.

Параметр `min_cluster_size` задаёт минимальный размер группы, а `min_samples` — число объектов m для оценки плотности. В `scikit-learn` при `min_samples=None` используется значение `min_cluster_size`; для раздельного изучения их влияния оба параметра задают явно.

Устойчивость по уровням плотности не равна устойчивости к подвыборке. Сила принадлежности в HDBSCAN также не является вероятностью происхождения из гауссовой компоненты. Смысл найденных групп проверяют по их составу, размерам и доле шума.

12 Смесь распределений: пример с покупателями

Вернёмся к магазину. Одна часть покупателей обычно собирает небольшие корзины, другая — более крупные. Но поведение не подчиняется жёсткой границе: постоянный покупатель иногда делает большой заказ, а оптовый клиент может прийти за одной недостающей позицией. Чек между двумя типичными значениями допускает несколько объяснений.

К-means всё равно присвоит ему одну метку. Вероятностная модель позволяет сохранить неопределённость: оценить, насколько каждое объяснение согласуется с наблюдением. Для этого группу описывают не только центром, но и распределением значений вокруг него.

12.1 Что означает «смесь»

Представим, что наблюдение появляется в два этапа. Сначала выбирается неизвестная нам группа покупателя. Затем из распределения этой группы получается его средний чек. Мы видим чек, но не видим первый выбор. Эта скрытая метка и создаёт задачу для ЕМ.

Группу опишем нормальным распределением. Среднее μ_k задаёт типичный чек, дисперсия σ_k^2 — разброс, а вес π_k — распространённость группы. Общая плотность складывается из взвешенных плотностей:

$$p(x) = \sum_k \pi_k \mathcal{N}(x \mid \mu_k, \sigma_k^2), \quad \pi_k \geq 0, \quad \sum_k \pi_k = 1.$$

На практике у денежных признаков часто длинный правый хвост. В семинаре перед моделированием используется логарифм средней корзины. Тогда нормальные компоненты описывают распределение именно в преобразованной шкале. Для объяснения шагов ниже достаточно условной шкалы от небольших корзин к большим.


12.2 Почему нельзя просто посчитать средние

Если бы группы были известны, мы отдельно посчитали бы их средние, разбросы и доли. Если бы параметры распределений были известны, мы могли бы сравнить, какая группа лучше объясняет каждого покупателя. Но неизвестно и то, и другое.

ЕМ использует эту зависимость как способ обучения. Сначала берём приблизительные параметры. По ним оцениваем принадлежность. По принадлежности пересчитываем параметры. Никакой готовой разметки для первого шага не требуется: достаточно начального предположения о распределениях.

13 Е-шаг: несколько объяснений одной покупки

На рисунке синий колокол описывает меньшие корзины, оранжевый — большие. Это начальное предположение, а не уже найденные группы. Покупатель А расположен ближе к области, типичной для синего распределения; покупатель В — к оранжевому; для покупателя Б оба объяснения выглядят правдоподобно.




Чтобы сравнить объяснения, для каждой компоненты берём плотность около наблюдаемого значения и умножаем её на долю компоненты. Затем делим полученные веса на общую сумму:

$$r_{ik} = P(z_i = k \mid x_i, \theta) = \frac{\pi_k \mathcal{N}(x_i \mid \mu_k, \sigma_k^2)}{\sum_{\ell} \pi_{\ell} \mathcal{N}(x_i \mid \mu_{\ell}, \sigma_{\ell}^2)}.$$

Это формула Байеса. Числитель оценивает совместное объяснение «покупатель из этой группы и у него такой чек». Знаменатель складывает все возможные групповые объяснения. После нормировки вероятности для одного покупателя дают единицу.

Плотность не является вероятностью отдельного точного значения. Однако для узкого интервала около чека вероятность приблизительно равна плотности, умноженной на ширину интервала. При сравнении групп одинаковая ширина сокращается — поэтому плотности позволяют вычислить относительные веса объяснений.



Столбец относится к одному покупателю. Цветные части показывают неопределённость его скрытой метки. Мы не утверждаем, что человек «состоит» из нескольких типов. Мы оставляем несколько возможностей, пока наблюдение не позволяет уверенно их различить. Этот пересчёт называют Е-шагом: expectation, условное математическое ожидание неизвестных индикаторов принадлежности.

14 М-шаг: покупатели влияют на параметры с разными весами

Теперь временно зафиксируем вычисленные вероятности. Покупатель А сильно влияет на параметры синей группы, покупатель В — на оранжевую. Покупатель Б влияет на обе: его наблюдение пока поддерживает оба объяснения. Поэтому среднее каждой группы нужно считать с весами r_{ik} .

$$N_k = \sum_i r_{ik}, \quad \mu_k^{\text{new}} = \frac{\sum_i r_{ik} x_i}{N_k}.$$

Сумма N_k — ожидаемая численность группы. Она может быть дробной, поскольку складываются вероятности, а не окончательные метки. Деление на неё нормирует вклад покупателей. Если вместо вероятностей подставить жёсткие назначения, получится обычное среднее своей группы.

Точно так же пересчитываем долю и разброс:

$$\pi_k^{\text{new}} = \frac{N_k}{n}, \quad \sigma_k^{2\text{new}} = \frac{\sum_i r_{ik} (x_i - \mu_k^{\text{new}})^2}{N_k}.$$

Разброс измеряется относительно нового среднего. Наблюдения с большим весом сильнее определяют и положение, и ширину колокола. Если поддерживающие компоненту покупки близки друг к другу, распределение сужается; если различаются — остаётся широким. Деление на N_k , а не на $N_k - 1$, связано с оценкой максимального правдоподобия.

Это М-шаг: maximization. Он выбирает параметры, которые лучше всего согласуются с текущими мягкими назначениями. Во время этого шага веса фиксированы: менять одновременно и веса, и параметры означало бы решать другую задачу.


14.1 Почему ближайшее среднее не всегда побеждает

Представим покупателя между двумя средними. Если формы распределений и доли совпадают, основания предпочесть одно объяснение другому нет. Если одна группа распространена сильнее, её объяснение получает больший начальный вес. Если различается разброс, важна ещё и форма плотности: узкий колокол высок около среднего, но быстро убывает вдали от него.

Поэтому GMM не сводится к выбору ближайшего среднего. Два покупателя на одинаковом расстоянии от центров могут иметь разные вероятности принадлежности при разных ковариациях или долях компонент.

15 Зачем повторять Е- и М-шаги

После М-шага распределения сдвинулись и изменили ширину. Теперь они иначе объясняют покупателей. Препные веса были рассчитаны по старым колоколам, поэтому их нужно обновить. Новый Е-шаг пересчитывает вероятности, а следующий М-шаг снова использует их как веса.



Столбцы показывают условную выборку покупателей. Цветные кривые — взвешенные компоненты, чёрная — их сумма. Сначала описание грубое. После повторения шагов положения и ширины лучше согласуются с наблюдаемой формой. Сами покупатели при этом не перемещаются: меняется модель их распределения.

15.1 Что именно улучшается

Обозначим все параметры через θ . Правдоподобие независимых наблюдений равно $L(\theta) = \prod_i p(x_i | \theta)$. Модель получает большую оценку, если даёт большую плотность в наблюдаемых значениях. Удобнее работать с логарифмом:

$$\ell(\theta) = \sum_i \log \left[\sum_k \pi_k \mathcal{N}(x_i | \mu_k, \sigma_k^2) \right].$$

Логарифм превращает произведение в сумму и помогает численным вычислениям. Это не доля угаданных меток: правильных меток алгоритм вообще не видел. Точный ЕМ не уменьшает правдоподобие, но может остановиться в локальном решении. Обычно шаги прекращают, когда дальнейшее улучшение мало.

Описать плотность и найти полезные покупательские сегменты — разные результаты. В реальных данных семинара несколько компонент могут описывать основную массу и хвост одного распределения. Само наличие нескольких колоколов не доказывает существование нескольких содержательных групп.

15.2 Неубывание правдоподобия в EM

Разберём, почему чередование E- и M-шагов не уменьшает правдоподобие. Обозначим параметры смеси через θ , наблюдения — через x_i , неизвестную группу покупателя — через z_i . Максимизируем логарифм правдоподобия

$$\ell(\theta) = \sum_{i=1}^n \log p(x_i | \theta) = \sum_{i=1}^n \log \sum_{k=1}^K p(x_i, z_i = k | \theta).$$

Сумма внутри логарифма мешает оценивать компоненты отдельно. При известных группах каждый покупатель давал бы логарифм плотности одной компоненты. Получим похожую задачу с вероятностными весами вместо неизвестных меток.

Вспомогательная задача. Для каждого покупателя введём распределение по группам: $q_i(k) \geq 0$, $\sum_k q_i(k) = 1$. Число $q_i(k)$ — вес предположения «покупатель i относится к группе k ». Эти веса пока произвольны и не обязаны совпадать с вероятностями модели. Обозначим их совокупность $q = (q_1, \dots, q_n)$.

При положительных весах верно тождество

$$p(x_i | \theta) = \sum_k q_i(k) \frac{p(x_i, z_i = k | \theta)}{q_i(k)}.$$

Само умножение и деление на $q_i(k)$ ничего не меняет. Но по неравенству Йенсена для вогнутого логарифма получаем *нижнюю границу*:

$$\ell(\theta) \geq \mathcal{F}(q, \theta), \quad \mathcal{F}(q, \theta) = \sum_{i,k} q_i(k) \log \frac{p(x_i, z_i = k | \theta)}{q_i(k)}.$$

Разные q задают разные границы одной функции ℓ . Поэтому q становится дополнительной переменной: будем выбирать границу, точную при текущих параметрах. При фиксированном q получаем удобную взвешенную сумму логарифмов совместных плотностей; слагаемое $-\sum_{i,k} q_i(k) \log q_i(k)$ от θ не зависит.

Расхождение распределений. Для распределений $a = (a_1, \dots, a_K)$ и $b = (b_1, \dots, b_K)$ на одних и тех же группах *KL-дивергенция* определяется как

$$\text{KL}(a||b) = \sum_{k=1}^K a_k \log \frac{a_k}{b_k}.$$

Это средний по a логарифм отношения вероятностей. Всегда $\text{KL}(a||b) \geq 0$, причём равенство возможно только при $a = b$. Для положительных вероятностей это следует из $\log u \leq u - 1$ при $u = b_k/a_k$. KL измеряет расхождение, но не является расстоянием: перестановка распределений может изменить значение.

Слагаемые с $a_k = 0$ считаются нулевыми; при $a_k > 0$, $b_k = 0$ дивергенция бесконечна. В нашей смеси с положительными долями и невырожденными гауссовыми компонентами апостериорные вероятности положительны. Граница при нулевых $q_i(k)$ определяется по непрерывности.

Чередование шагов. Обозначим через $p_i^\theta(k) = p(z_i = k \mid x_i, \theta)$ распределение групп по самой модели. Подставляя $p(x_i, z_i = k \mid \theta) = p_i^\theta(k)p(x_i \mid \theta)$ в границу, получаем

$$\begin{aligned}\mathcal{F}(q, \theta) &= \sum_{i,k} q_i(k) [\log p(x_i \mid \theta) + \log p_i^\theta(k) - \log q_i(k)] \\ &= \ell(\theta) - \sum_i \text{KL}(q_i \parallel p_i^\theta).\end{aligned}$$

На Е-шаге параметры θ^{old} фиксированы, поэтому $\ell(\theta^{\text{old}})$ постоянно. Максимизация границы по q сводится к минимизации суммы KL-дивергенций. Каждая из них обращается в нуль при выборе

$$q_i^*(k) = p_i^{\theta^{\text{old}}}(k) = p(z_i = k \mid x_i, \theta^{\text{old}}) = r_{ik}.$$

Таким образом, произвольность q позволяла выбирать веса. Е-шаг находит оптимальный выбор: апостериорные вероятности r_{ik} , при которых граница совпадает с текущим правдоподобием. Их вычисляют по формуле Байеса, без численного поиска по q .

На М-шаге фиксируем веса q^* и подбираем параметры, не уменьшающие $\mathcal{F}(q^*, \theta)$:

$$\ell(\theta^{\text{new}}) \geq \mathcal{F}(q^*, \theta^{\text{new}}) \geq \mathcal{F}(q^*, \theta^{\text{old}}) = \ell(\theta^{\text{old}}).$$

Первое неравенство следует из свойства нижней границы, второе обеспечивает М-шаг, последнее равенство — точный Е-шаг. После обновления параметров граница может снова стать неточной. Следующий Е-шаг пересчитает веса, и цикл повторится.

15.3 Почему М-шаг даёт взвешенные оценки

При фиксированном $q_i(k) = r_{ik}$ слагаемые $-\sum r_{ik} \log r_{ik}$ не зависят от параметров. Остаётся максимизировать

$$Q(\theta) = \sum_{i,k} r_{ik} [\log \pi_k + \log \mathcal{N}(x_i \mid \mu_k, \sigma_k^2)].$$


Логарифм нормальной плотности содержит $-(x_i - \mu_k)^2 / (2\sigma_k^2)$. Поэтому условие оптимальности по среднему даёт $\sum_i r_{ik}(x_i - \mu_k) = 0$, то есть взвешенное среднее. Производная по дисперсии даёт взвешенный квадрат отклонений. Для долей используется ограничение $\sum_k \pi_k = 1$, откуда $\pi_k = N_k/n$.

Гарантия относится к точному Е-шагу и М-шагу, который не уменьшает вспомогательную функцию. Если в реализацию добавлены штрафы или ограничения, нужно уточнить её целевой критерий. Даже монотонный ЕМ может прийти к локальному решению: доказательство сравнивает соседние итерации, а не все возможные параметры.

16 Смесь Гаусса в нескольких измерениях

Если покупателя описывают средний чек и частота покупок, среднее группы становится вектором. Вместо дисперсии нужна ковариационная матрица Σ_k . Её диагональные элементы задают разбросы координат, а внедиагональные — их совместные изменения.

Например, в группе более частые покупатели могут в среднем делать менее дорогие покупки. Тогда облако вытянуто по наклонному направлению. Полная ковариационная матрица описывает такой наклон, диагональная — только вытянутость вдоль осей. Сферическая ковариация $\sigma_k^2 I$ задаёт одинаковый разброс во всех направлениях.



Общая модель смеси записывается как

$$p(x | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k).$$

Е-шаг имеет ту же структуру, что и на прямой:

$$r_{ik} = \frac{\pi_k \mathcal{N}(x_i | \mu_k, \Sigma_k)}{\sum_{\ell} \pi_{\ell} \mathcal{N}(x_i | \mu_{\ell}, \Sigma_{\ell})}.$$

На М-шаге $N_k = \sum_i r_{ik}$, доли и средние пересчитываются по прежним формулам, а ковариация — по взвешенным отклонениям:

$$\Sigma_k^{\text{new}} = \frac{1}{N_k} \sum_i r_{ik} (x_i - \mu_k^{\text{new}})(x_i - \mu_k^{\text{new}})^{\top}.$$

Для жёстких меток можно выбрать $\arg \max_k r_{ik}$. Но полезно сохранить и сами вероятности: они показывают точки, для которых несколько объяснений сопоставимы. Даже очень большая вероятность относится к выбранной модели; если сама модель не подходит данным, она может быть уверенной и при неверной интерпретации групп.

17 Инициализация ЕМ, вырождение и выбор модели

Если обе компоненты начать с одинаковых средних, дисперсий и долей, Е-шаг будет давать всем точкам одинаковые вероятности двух групп. М-шаг посчитает два одинаковых взвешенных средних. Компоненты не разойдутся сами: симметрия сохранится. Это объясняет, зачем нужны различающиеся начальные параметры.

Обычно пробуют несколько инициализаций, в том числе центры K-means, и сравнивают итоговое правдоподобие. Разные запуски могут привести к разным локальным решениям. Перестановка номеров одинаковых компонент, напротив, не меняет смесь.

17.1 Что произойдёт с компонентой из одной точки

Представим, что одна компонента практически целиком отвечает за одно наблюдение. Она может поставить среднее в эту точку и уменьшать дисперсию. Плотность в центре нормального распределения растёт при уменьшении стандартного отклонения. Поэтому для неограниченной смеси максимальное правдоподобие может вырождаться: всё более узкая компонента даёт всё большее значение критерия.

Практические реализации ограничивают ковариации или добавляют небольшое число к их диагонали. В `GaussianMixture` за это отвечает `reg_covar`. Такой параметр не следует путать с разбросом данных: он защищает вычисления и ограничивает вырождение модели.

17.2 Число компонент и BIC

До сих пор мы предполагали, что число компонент уже выбрано. Но для истории покупок заранее неизвестно, достаточно ли двух колоколов или нужны дополнительные компоненты. Более сложная смесь может лучше описать асимметрию и длинный хвост распределения. Она также получает больше возможностей подстроиться под случайные особенности именно этой выборки.

Поэтому сравнивать модели только по правдоподобию недостаточно: хорошее описание обучающих данных ещё не оправдывает добавление новых параметров. Нужен критерий, который учитывает и соответствие данным, и сложность модели.

Один из таких критериев — *байесовский информационный критерий*, или BIC:

$$\text{BIC} = -2\ell(\hat{\theta}) + \nu \log n.$$

Здесь n — число наблюдений, $\hat{\theta}$ — оценённые параметры рассматриваемой модели, $\ell(\hat{\theta})$ — логарифм её правдоподобия, а ν — число свободных параметров. Первое слагаемое уменьшается при улучшении описания данных, второе штрафует за сложность. Среди сравниваемых моделей предпочитают меньший BIC. Дополнительная компонента оправдывается по этому критерию только тогда, когда выигрыш в правдоподобию достаточен, чтобы компенсировать рост штрафа.

Для смеси из K гауссовых компонент в пространстве размерности d с отдельной полной ковариационной матрицей у каждой компоненты

$$\nu = (K - 1) + Kd + K \frac{d(d + 1)}{2}.$$

У долей смеси $K - 1$ свободных значений: последнее определяется условием, что сумма равна единице. У каждого из K средних есть d координат. Каждая симметричная ковариационная матрица содержит $d(d + 1)/2$ независимых элементов.

На практике обучают несколько моделей с разным K , для каждой пробуют несколько инициализаций и затем сравнивают BIC. Объекты, признаки и их преобразования должны быть одинаковыми. Иначе меняется сама задача, и значения критерия уже нельзя сопоставлять таким способом.

Меньший BIC указывает на предпочтительную модель среди проверенных вариантов, но не доказывает число содержательных покупательских групп. Например, одному сегменту с асимметричным распределением чека могут понадобиться две гауссовы компоненты. Кроме того, обычное асимптотическое обоснование BIC требует осторожности для смесей из-за их статистических особенностей.

18 Связь ЕМ с K-means

Предположим, что у всех компонент одинаковые веса и одна и та же фиксированная сферическая ковариация $\sigma^2 I$. Тогда

$$r_{ik} = \frac{\exp(-\|x_i - \mu_k\|^2 / (2\sigma^2))}{\sum_{\ell} \exp(-\|x_i - \mu_{\ell}\|^2 / (2\sigma^2))}.$$

В формуле остаются только расстояния до средних. При большой σ различия сглажены: несколько центров могут объяснять точку. При уменьшении σ разница между близким и далёким центром усиливается.

Если ближайший центр единственный, при $\sigma^2 \rightarrow 0$ его вес стремится к 1, а остальные — к 0. Взвешенное среднее М-шага превращается в обычное среднее группы. Так из мягких шагов для средних получаются шаги Ллойда.

Этот переход требует указанных ограничений. При разных ковариациях или конечной дисперсии обычный ЕМ не совпадает с K-means. Если два центра находятся на одинаковом минимальном расстоянии, между ними может сохраниться разделение веса.

18.1 Что отличает цели методов

K-means минимизирует сумму квадратов до выбранных центров. GMM описывает всю плотность данных, включая разбросы и доли компонент. Мягкие назначения следуют из вероятностной модели, а не добавляются к K-means произвольным правилом.

На практике смесь может быть полезна и без превращения компонент в кластеры. Например, модель плотности позволяет оценивать типичность наблюдений. И наоборот, хорошее приближение плотности не гарантирует, что каждая компонента будет удобным покупательским сегментом. Чтобы дать группе название, всё ещё нужно рассмотреть её объекты и признаки.

18.2 Что стоит помнить о примере

Группа с небольшими корзинами и группа с большими корзинами могут перекрываться. ЕМ сохраняет эту неопределённость, вместо того чтобы сразу проводить жёсткую границу. Сначала каждый покупатель получает несколько весов, затем эти веса управляют пересчётом параметров. Повторение нужно потому, что обновлённые группы иначе объясняют те же наблюдения.


19 Как выбирать метод

Если группы ожидаются компактными и выборка большая, K-means даёт удобное начальное решение. Иерархия полезна, когда нужно рассматривать несколько уровней детализации. DBSCAN и HDBSCAN подходят для поиска плотных протяжённых областей с шумом. GMM позволяет моделировать эллипсоидальные облака и сохранять неопределённость назначений.

Это начальные предположения, которые следует проверить экспериментом. Полезно сравнивать не только итоговую метрику, но и размеры групп, характерные объекты, шум и изменения при близких параметрах. Если смысл групп невозможно объяснить через признаки, стоит вернуться к представлению данных.

19.1 Проверка на реальной истории покупок

В семинаре используется Online Retail: открытая история заказов интернет-магазина. Строка исходной таблицы описывает товарную позицию, поэтому сначала нужно собрать заказы и только затем профили покупателей. В признаки входят давность последней покупки, число заказов и средняя стоимость корзины. Идентификаторы нужны для объединения записей, но расстояния между их числовыми значениями не имеют смысла.



Преобразование признаков и выбор метода отвечают на разные вопросы. Логарифм сжимает длинные хвосты, стандартизация задаёт сопоставимый масштаб, K-means ищет компактные профили в получившейся геометрии. Для интерпретации возвращаемся к исходным единицам и описываем типичного покупателя группы. Затем меняем число групп, состав выборки и предположения алгоритма.

У реальных данных нет обязанности образовывать отдельные облака. Число заказов дискретно, и плотностный метод может выделить полосы этого признака. Такой результат объясняется геометрией, но ещё не подтверждает содержательное различие сегментов.

19.2 Обучаемые представления

Для текстов и изображений расстояние между исходными координатами может плохо отражать смысл. Можно сначала получить вектор $h_i = f_\theta(x_i)$ с помощью обученной модели, затем кластеризовать эти векторы обычным методом. По-прежнему нужно выбрать нормировку, метрику и способ оценки. Для текстов простой вариант сравнения — TF-IDF с K-means.

Литература

1. Dempster, A. P., Laird, N. M., Rubin, D. B. (1977). *Maximum Likelihood from Incomplete Data via the EM Algorithm*. Journal of the Royal Statistical Society, Series B. [Статья](#).
2. Ester, M., Kriegel, H.-P., Sander, J., Xu, X. (1996). *A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise*. KDD. [Статья](#).
3. Campello, R. J. G. B., Moulavi, D., Sander, J. (2013). *Density-Based Clustering Based on Hierarchical Density Estimates*. PAKDD. [Статья](#).
4. hdbscan developers. *How HDBSCAN Works*. Руководство пользователя. [Документация](#).
5. Chen, D. (2015). *Online Retail* [набор данных]. UCI Machine Learning Repository. [Данные](#).
6. scikit-learn developers. *Clustering*. Руководство пользователя. [Документация](#).
7. scikit-learn developers. *Gaussian mixture models*. Руководство пользователя. [Документация](#).
8. SciPy developers. *scipy.cluster.hierarchy.linkage*. Справочник API. [Документация](#).