

Лекция 2. Графовые модели

Дополнительные главы машинного обучения

Образовательная программа
«Машинное обучение в цифровом продукте»

Оглавление

1) Задача продукта и графовые данные

2) Спектральная кластеризация


3) Представления и распространение информации

4) Графовые нейронные сети

5) Применение и ограничения

На прошлом семинаре мы получили сегменты покупателей

Описали каждого покупателя тремя признаками: давность покупки, число заказов и средняя корзина.



Группы различаются покупательской активностью. Состав заказов в эти признаки не входит.

А если интерес покупателя изменился?

Покупатель обычно заказывал свечи и декор. А что, если в последних заказах появились чашки и чайник?

- Число заказов и средняя корзина могут остаться почти прежними.
- Покупатель может остаться в том же сегменте.
- При этом появились покупки, которые могут указывать на другой интерес.

Что предложить дальше: ещё свечи или товары, связанные с последними покупками?

Задача продукта: десять персональных рекомендаций

В блоке «Вам может понравиться» нужно выбрать товары для конкретного покупателя.

- **Вход:** история покупок, включая последние заказы.
- **Выход:** десять доступных товаров, которых ещё нет в его истории.
- **Базовое решение:** популярные товары с исключением уже купленного.

Гипотеза: состав покупок и связи между товарами помогут точнее учесть интерес человека.

По истории проверяем попадания в будущие покупки. Влияние рекомендаций на продажи проверяем в продукте.

Вернёмся к исходной истории заказов

Та же таблица Online Retail: заказы магазина подарков за декабрь 2010 - декабрь 2011 года. Среди клиентов есть оптовики.

Заказ	Покупатель	Товар	Количество
536365	17850	Подсвечник в форме сердца	6
536365	17850	Белый металлический фонарь	6
536365	17850	Вешалка с сердцами	8

541 909 строк: каждая описывает **товарную позицию в заказе**. Названия выше переведены для чтения.

Есть время, количество и цена. Нет показов рекомендаций, кликов и надёжной истории складских остатков.

Два графа одной истории покупок

Пользователи и товары

$$R_{ui} = \mathbb{1}\{u \text{ покупал } i\}.$$

Два типа вершин. Рёбра соединяют покупателя с товаром.

Предсказываем, какая новая связь может появиться.

Граф сохраняет связи между объектами. Чтобы учитывать свежесть покупок, нужно отдельно задать временное окно или веса событий.

Товары и совместные покупки


$$W_{ij} = \text{сила совместной покупки } i, j.$$

Один тип вершин. Рёбра связывают товары, встречавшиеся в одних заказах. Ищем группы и соседей товаров.

Вершины, рёбра, признаки и веса

$G = (V, E)$: V - вершины, E - связи между ними.

Совместные покупки



x_v : описание, цена, материал

Цитирование



- **Вершина:** объект с признаками x_v .
- **Ребро:** связь с признаками: тип события, время, число покупок.
- **Вес:** сила связи. Здесь толстое ребро означает большой вес.
- **Направление:** у совместной покупки его нет, у цитирования есть.

Вес зависит от задачи: сходство больше - связь сильнее; время пути больше - ехать дольше.

Матрицы графа: связи, признаки и степени

Порядок вершин: **1 - чашка, 2 - чайник, 3 - свеча.**

Взвешенная матрица смежности

$$W \in \mathbb{R}^{n \times n}$$

$$W = \begin{pmatrix} 0 & 0,8 & 0,2 \\ 0,8 & 0 & 0 \\ 0,2 & 0 & 0 \end{pmatrix}$$

$w_{12} = 0,8$: связь чашки с чайником. Ноль означает отсутствие ребра.

Матрица признаков вершин

$$X \in \mathbb{R}^{n \times d}$$

$$X = \begin{pmatrix} 8 & 200 \\ 25 & 800 \\ 5 & 100 \end{pmatrix}$$

Строки: товары.
Столбцы: цена (£) и масса (г). $n = 3$ товара; $d = 2$ признака.

Диагональная матрица взвешенных степеней

$$D \in \mathbb{R}^{n \times n}$$

$$D = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0,8 & 0 \\ 0 & 0 & 0,2 \end{pmatrix}$$

$D_{ii} = \sum_j w_{ij}$.
У чашки
 $D_{11} = 0,8 + 0,2 = 1$.

Взвешенная степень суммирует веса связей: у чашки она равна 1, а число соседей равно 2.

Порядок вершин и хранение графа

Один и тот же порядок нужен в строках X , строках и столбцах W и D .

Индекс	Было	Стало
1	Чашка	Чашка
2	Чайник	Свеча
3	Свеча	Чайник

- В X меняем строки 2 и 3.
- В W и D меняем **и строки, и столбцы** 2 и 3.

После перестановки $w'_{12} = 0,2$, $w'_{13} = 0,8$:
сами связи не изменились.

Переставить только X означает приписать чайнику признаки свечи. Размеры матриц не обнаружат эту ошибку.

Индекс обозначает место объекта в матрице и не является мерой близости.

Разреженное хранение W : записываем ненулевые веса и их индексы. При m рёбрах требуется порядка $n + m$ элементов вместо n^2 . Признаки X хранятся отдельно.

Что предсказываем: вершину, связь или целый граф?

Задача	Объект предсказания	Пример
Node classification	Одна вершина	Категория товара по признакам и окружению
Link prediction	Пара вершин	Покупка товара пользователем
Graph classification	Отдельный граф	Метка молекулы по графу атомов и связей

В нашей истории основная задача - **ранжирование потенциальных связей**. Для остальных задач меняются ответы, функция потерь и единица разбиения данных.

Оглавление

1) Задача продукта и графовые данные

2) Спектральная кластеризация


3) Представления и распространение информации

4) Графовые нейронные сети

5) Применение и ограничения

Группы в графе совместных покупок

Рёбра показывают совместные покупки; их веса отражают силу связи.



Ищем группы по связям:

- Внутри группы много сильных связей.
- Между группами связи слабые.

DBSCAN: плотные области по расстоянию, ϵ и числу соседей.

Спектральная кластеризация: представление из графа, затем разделение вершин на группы.

Положение вершин на рисунке произвольно: группы определяются связями.

Граф можно получить из признаков или взаимодействий

- ε -граф: соединяем достаточно близкие объекты.
- k -NN-граф: соединяем объект с k ближайшими соседями, затем симметризуем связи.
- Полный взвешенный граф: $w_{ij} = \exp(-\|x_i - x_j\|^2 / (2\sigma^2))$ при $i \neq j$.
- Граф взаимодействий: используем совместные покупки или другие наблюдаемые события.

Малое число соседей может разорвать группу. Слишком большое соединит разные области.

Для спектрального разбора предполагаем симметричные неотрицательные веса.

Веса совместных покупок

Пусть $B_{oi} = 1$, если товар i входит в заказ o . Тогда

$$C = B^T B, \quad w_{ij} = \frac{C_{ij}}{\sqrt{C_{ii}C_{jj}}}, \quad i \neq j.$$

- C_{ij} - число заказов с обоими товарами.
- Нормировка ослабляет преимущество очень частых товаров.
- Для разреженного графа можно оставить k сильнейших соседей и симметризовать веса.

Интерпретация: товары покупают вместе. Они могут дополнять друг друга, а не заменять.

Лапласиан графа

$$L = D - W, \quad D_{ii} = \sum_j w_{ij}.$$

W: связи

1	0	1	0
2	1	0	1
3	0	1	0
	1	2	3

D: степени

1	1	0	0
2	0	2	0
3	0	0	1
	1	2	3

L = D - W

1	1	-1	0
2	-1	2	-1
3	0	-1	1
	1	2	3

Пример: цепочка из трёх вершин 1-2-3 с единичными весами.

Диагональ учитывает суммарный вес связей вершины, внедиагональные элементы - её связи с соседями.

Вектор как сигнал на вершинах

Вектор $f \in \mathbb{R}^n$ задаёт по одному числу для каждой вершины.


$$(Lf)_i = \sum_j w_{ij}(f_i - f_j).$$

- Если сигнал одинаков у вершины и её соседей, эта величина равна нулю.
- Большие различия на сильных связях дают большой вклад.

$L\mathbf{1} = 0$: сумма весов соседей равна степени вершины. Постоянный сигнал - собственный вектор для значения 0.

Энергия сигнала на графе

$$f^\top L f = \frac{1}{2} \sum_{i,j} w_{ij} (f_i - f_j)^2 \geq 0.$$



На рисунке две тройки с единичными внутренними связями и мостиком веса 0,12.

Низкая энергия допускает различие между группами, если связи между ними слабые. При этом внутри группы сигнал почти постоянен.



Нулевой спектр показывает компоненты связности

Утверждение. Число нулевых собственных значений L с учётом кратности равно числу компонент связности.

1. Если $Lf = 0$, то $\sum_{i,j} w_{ij}(f_i - f_j)^2 = 0$.
2. Каждое слагаемое неотрицательно. На ребре положительного веса $f_i = f_j$.
3. По пути это равенство переносится на всю компоненту.

Значит, f постоянен на каждой компоненте. Индикаторы компонент дают базис ядра L .

Слабые связи и малые собственные значения



Для нормированного собственного вектора $\|f\| = 1$ выполняется $f^\top L f = \lambda$. Малое λ означает небольшую **суммарную** вариацию на рёбрах.

Это объясняет почти постоянные значения внутри хорошо связанных групп. Универсальной гарантии разделить любые бизнес-категории здесь нет.

Разрез графа и баланс групп

$$\text{cut}(A, \bar{A}) = \sum_{i \in A, j \in \bar{A}} w_{ij}.$$

Простой минимум разреза может отделить одну слабо связанную вершину.

$$\text{Ncut}(A, \bar{A}) = \frac{\text{cut}(A, \bar{A})}{\text{vol}(A)} + \frac{\text{cut}(A, \bar{A})}{\text{vol}(\bar{A})}, \quad \text{vol}(A) = \sum_{i \in A} D_{ii}.$$

Нормировка учитывает объём групп. Спектральное решение возникает после непрерывного ослабления дискретной задачи разбиения.

Собственные векторы дают новые признаки

Для вершин ненулевой степени:

$$L_{\text{sym}} = I - D^{-1/2} W D^{-1/2}.$$

1. Находим K собственных векторов для наименьших собственных значений.
2. Записываем их столбцами матрицы $U \in \mathbb{R}^{n \times K}$.
3. Нормируем ненулевые строки U до единичной длины.
4. Запускаем K-means на строках: одна строка соответствует одному товару.

Это вариант алгоритма для нормированного лапласиана. Изолированные вершины обрабатываем отдельно.

Что дают группы для рекомендаций

1. По истории покупателя оцениваем долю интереса к каждой группе.
2. Предпочитаем товары из более интересных групп.
3. Внутри группы ранжируем по популярности и исключаем уже купленное.

Ограничение: жёсткая группа теряет различия между товарами и пересечения интересов. Кластеризация описывает структуру графа, а рекомендации оцениваем по будущим действиям покупателей.

Оглавление

1) Задача продукта и графовые данные

2) Спектральная кластеризация

3) Представления и распространение информации

4) Графовые нейронные сети

5) Применение и ограничения

Embedding: положение вершины в пространстве признаков


$$v \longmapsto z_v \in \mathbb{R}^d, \quad d \ll |V|.$$

- Ручные признаки описывают степень, соседей или характеристики товара.
- Спектральные признаки отражают плавные изменения на графе.
- Обучаемые embeddings настраиваем под соседства или целевую задачу.

Профиль покупателя можно получить усреднением embeddings его товаров. Близость к этому профилю задаёт score кандидата.

Выбор представления и выбор целевой функции определяют, что означает «похожий».

Случайное блуждание задаёт контекст вершины



Начинаем с вершины и несколько раз переходим к соседям. Последовательность посещений играет роль предложения, а вершины - слов. Учимся предсказывать контекст вершины по её embedding.

DeepWalk и node2vec

DeepWalk: обычные случайные блуждания и обучение по локальному контексту.

node2vec: переход учитывает предыдущую вершину. Параметры p и q меняют склонность возвращаться и уходить дальше.

- Локальный контекст помогает описывать сообщества.
- Другая стратегия обхода может лучше отражать структурные роли.
- Готовые векторы используем в классификаторе или для поиска кандидатов.

Новая вершина обычно требует дополнительного вычисления представления. Таблица embeddings не задаёт автоматически функцию для любого нового объекта.

Распространение интереса по товарному графу

Нормируем веса исходящих связей:

$$P = D^{-1}W, \quad s_u = r_u P.$$

r_u - строка покупок пользователя, s_u - score товаров после одного шага.

История	Свеча	Подсвечник	Кружка
Покупал	1	0	0
Переход из свечи	0	0,8	0,2

Первым кандидатом будет подсвечник. У вершины без соседей нужен отдельный способ выдачи рекомендаций.

Распространение меток: node classification

Пусть у части товаров известны категории. $Y \in \mathbb{R}^{n \times C}$ хранит известные метки, остальные строки нулевые.

$$F^{(t+1)} = \alpha P F^{(t)} + (1 - \alpha) Y, \quad 0 < \alpha < 1.$$

Соседи передают оценки классов. Возврат к Y сохраняет влияние исходной разметки.

- Метод полезен, если связи часто соединяют вершины одного класса.
- Для жёсткого закрепления известных ответов после шага восстанавливают их строки.

Это другая задача, чем распространение покупательского интереса: здесь распространяются **классы**.

Смысл ребра важнее предположения о похожести

Гомофилия: связанные вершины часто имеют похожие признаки или метки.

- В графе сходства описаний соседство может поддерживать одинаковую категорию.
- В графе совместных покупок чашка может соседствовать с чайником.
- В двудольном графе покупатель всегда соседствует с вершиной другого типа.

Совместная покупка отражает контекст или дополнение. Для переноса категорий такое ребро может быть неудачным.

Оглавление

- 1) Задача продукта и графовые данные
- 2) Спектральная кластеризация
- 3) Представления и распространение информации
- 4) Графовые нейронные сети**
- 5) Применение и ограничения

Обучаемое распространение информации

Фиксированное усреднение соседей задаёт одно правило. Графовая нейросеть обучает преобразование признаков под целевую задачу.


$$m_v^{(l)} = \text{AGG}\{h_u^{(l)} : u \in \mathcal{N}(v)\},$$

$$h_v^{(l+1)} = \text{UPDATE}_{\theta_l}(h_v^{(l)}, m_v^{(l)}).$$


$h_v^{(0)} = x_v$ - исходные признаки. Сообщение может также учитывать тип и признаки ребра.

Параметры общие для разных вершин: модель учится правилу обработки окружения.

Один шаг агрегации соседей




(1) Исходные векторы признаков




(2) Агрегируем признаки соседей

Сначала рассматриваем соседей вершины. Затем объединяем их текущие представления, например средним.

Собственное состояние и состояние соседей



(3) Комбинируем векторы признаков



(4) Вычисляем новые векторы признаков

Объединяем информацию и применяем обучаемое преобразование. Получаем новый вектор для каждой вершины.

Порядок соседей не должен менять результат

$$\text{mean}(a, b, c) = \text{mean}(c, a, b).$$

Сумма, среднее и максимум не зависят от перестановки соседей.

- Переименование вершин переставляет выходные векторы тем же образом.
- Для целого графа итоговый ответ должен сохраняться при переименовании.

Среднее может потерять число соседей: один сосед с вектором x и десять таких соседей дают одинаковое среднее.

GCN: нормированная агрегация и преобразование

Добавим собственные связи: $\tilde{A} = A + I$, $\tilde{D}_{ii} = \sum_j \tilde{A}_{ij}$.

$$H^{(l+1)} = \sigma\left(\tilde{D}^{-1/2} \tilde{A} \tilde{D}^{-1/2} H^{(l)} \Theta_l\right).$$

- $H^{(l)}$ хранит представления всех вершин.
- Нормировка учитывает степени вершины и соседа.
- Θ_l обучает преобразование признаков, σ добавляет нелинейность.

Здесь A обозначает смежность, а Θ_l - параметры модели: это разные объекты.

Несколько слоёв расширяют доступное окружение

Число слоёв	Какая информация может дойти до вершины
0	Её собственные исходные признаки
1	Признаки непосредственных соседей
2	Информация от вершин на расстоянии до двух рёбер

В графе «покупатель - товар» два шага связывают покупателя с другими покупателями через общие товары.

Дальние связи могут быть полезны, но вместе с ними приходит шум.

GraphSAGE и GAT: другие способы агрегации

GraphSAGE выбирает ограниченное число соседей и применяет общую функцию агрегации признаков. Может строить представление новой вершины по её признакам и окружению.

GAT обучает коэффициенты внимания к соседям:

$$h'_v = \sigma \left(\sum_{u \in \mathcal{N}(v) \cup \{v\}} \alpha_{vu} \Theta h_u \right), \quad \sum_u \alpha_{vu} = 1.$$

Внимание задаёт веса сообщений, но само по себе не доказывает причинную важность соседей.

Один encoder, разные выходы модели

Задача	Выход	Обучающий ответ
Вершина	$\hat{y}_v = \text{softmax}(Qh_v)$	Класс известной вершины
Связь	$s(u, i) = h_u^\top h_i$	Наблюдавшаяся пара или порядок кандидатов
Граф	$\hat{y}_G = g(\text{POOL}_{v \in V} h_v)$	Метка целого графа

Для классификации графов pooling объединяет разное число вершин в один вектор. Для классификации вершин loss вычисляем только по разрешённым обучающим меткам.

LightGCN: графовая модель для рекомендаций

В двудольном графе обучаем начальные embeddings покупателей и товаров:

$$E^{(l+1)} = D^{-1/2} A D^{-1/2} E^{(l)}, \quad \bar{E} = \frac{1}{L+1} \sum_{l=0}^L E^{(l)}.$$

- Здесь нет нелинейностей и матриц преобразования на каждом слое.
- Собственное представление сохраняется через включение $E^{(0)}$.
- Score пары: $s(u, i) = \bar{e}_u^\top \bar{e}_i$.

Базовая модель использует ID и связи покупок. Цена и текст товара в неё не входят.

Обучение ранжированию: BPR

Берём пользователя u , купленный товар i и ненаблюдавшийся товар j .

$$\mathcal{L} = - \sum_{(u,i,j)} \log \sigma(s(u,i) - s(u,j)) + \lambda \|E^{(0)}\|_F^2.$$

Хотим, чтобы купленный товар получил больший score.

- Отрицательные пары выбираем по обучающей истории.
- Отсутствие покупки не означает неприязнь: пользователь мог не видеть товар.
- При $L = 0$ получаем факторизацию с BPR. Это контроль вклада распространения по графу.

Оглавление

- 1) Задача продукта и графовые данные
- 2) Спектральная кластеризация
- 3) Представления и распространение информации
- 4) Графовые нейронные сети
- 5) Применение и ограничения**

Известный граф и новые объекты

Transductive

Вершины известны при обучении.

Часть ответов скрыта.

Таблица embeddings привязана к известным ID, как в базовой модели LightGCN.

Inductive

Модель применяем к новым вершинам или новым графам.

Нужны доступные признаки, окружение и общее правило вычисления представлений.

Для нового товара без взаимодействий требуется отдельное решение, например представление по тексту. Для нового покупателя возможна выдача популярных товаров.

Особенности и ограничения графовых моделей

- **Oversmoothing:** при многократном смешивании представления могут стать слишком похожими.
- **Рост окружения:** несколько слоёв охватывают много вершин. Выборка соседей ограничивает вычисления.
- **Качество рёбер:** ошибки и несоответствие смысла связей задаче распространяются по графу.
- **Время и типы связей:** покупка, просмотр и возврат не обязаны иметь одинаковый вклад.

Число слоёв и способ агрегации выбираем по проверке задачи. Больше связей и глубже модель не гарантируют лучшее качество.

Графовые модели в других продуктовых задачах

Приложение	Что связываем	Какое решение поддерживаем
Антифрод	Аккаунты, устройства, платежи	Какие события проверить
Поиск документов	Документы и цитирования	Какие материалы предложить
Каталог	Товары и сходство описаний	Какую категорию назначить
Молекулы	Атомы и химические связи	Какое свойство графа предсказать

Во всех случаях сначала задаём объект предсказания и смысл ребра, затем выбираем модель и способ проверки.

Материалы занятия

- Online Retail, UCI: Daqing Chen (2015), CC BY 4.0. История покупок.
- ФКН, весна 2026: кластеризация графов, представления и схемы агрегации.
- von Luxburg (2007): объяснение спектральной кластеризации.
- DeepWalk, node2vec: представления вершин.
- GCN, GraphSAGE, GAT: графовые нейросети.
- LightGCN, BPR: рекомендации и ранжирование.

Спасибо за внимание!